软件系统分析与设计作业

# 学术成果分享平台

# 核心模块开发规范

| 项目组成员信息 | |
|---|---|
| 小组编号 | 9 组 |
| 小组名称 | 1011101011 |
| 小组联系人 | 待填写 |

2026 年

# 版本变更历史

| 版本 | 提交日期 | 主要编制人 | 审核人 | 版本说明 |
| --- | --- | --- | --- | --- |
| v1.0 | 20261010 | 待填写 | 待填写 | 已有资料整合稿 |
| v1.1 | 20261010 | 待填写 | 待填写 | 原稿记载的文字整理 |
| v1.2 | 20261012 | 待填写 | 待填写 | 当前 images 图文同步 |
| v2.0 | 20261012 | 待填写 | 待填写 | 按参考仓库重构章节、用例与格式 |
| | | | | |
| | | | | |

# 目录

1 规范编号与共同契约 ..... 1
2 SPEC-INGEST-01 数据采集与增量同步 ..... 1
2.1 目标和输入输出 ..... 1
2.2 固定范围、幂等和检查点 ..... 2
2.3 六状态与处理阶段 ..... 2
2.4 配置与候选参数 ..... 2
2.5 验收 ..... 3
3 SPEC-DATA-01 清洗与字段规范化 ..... 3
3.1 固定处理顺序 ..... 3
3.2 字段状态与隔离 ..... 4
3.3 验收 ..... 4
4 SPEC-DATA-02 四类成果去重 ..... 4
4.1 一期可执行基线 ..... 4
4.2 候选匹配评分 ..... 4
4.3 合并输出及恢复 ..... 5
5 SPEC-DATA-03 人员与机构消歧 ..... 5
5.1 身份层次和一期规则 ..... 5
5.2 人员匹配候选评分 ..... 5
5.3 机构规范化 ..... 6
6 SPEC-SEARCH-01 检索与排序 ..... 6
6.1 输入与查询语义 ..... 6
6.2 默认排序与调优参数 ..... 6
6.3 索引与公开版本 ..... 7
6.4 验收 ..... 7
7 SPEC-CLAIM-01 身份、门户和成果管理 ..... 7
7.1 申请契约与材料 ..... 7
7.2 统一状态 ..... 7
7.3 原子授权与维护边界 ..... 8
7.4 验收 ..... 8
8 SPEC-STAT-01 统计、合作网络与推荐 ..... 8
8.1 统计集合与口径 ..... 8
8.2 共著与最短路径 ..... 9
8.3 P1 相关论文推荐 ..... 9
8.4 更新与验收 ..... 9
9 SPEC-QUALITY-01 质量、人工复核与审计 ..... 9
10 SPEC-TOOLS-01 私人科研资料能力 P1 ..... 10
11 逻辑接口与错误契约 ..... 10
12 架构候选与评审项 ..... 11
13 规范、代码与测试追踪及 AI 辅助开发 ..... 11
14 修订记录 ..... 12

**版本：v2.0 | 日期：2026-10-12**

本规范规定四类成果的采集、清洗、去重、身份匹配、检索、认领、统计及质量管理规则，包括模块输入输出、处理过程、异常恢复和验收方法。

需求与用例见 SRS，业务依据见调研报告，来源与修订情况见修订说明。算法参数和架构选型列为候选，采用前需完成固定样本测试和设计评审；性能要求为验收目标。

# 1 规范编号与共同契约

规范按九个模块编号，每项关联需求、模块输出和测试。早期五模块编号的对应关系保留，便于追踪。

| 规范编号 | 早期模块编号 | 对应需求 | 模块输出 |
|---|---|---|---|
| SPEC-INGEST-01 | SPEC-01 | FR-CRAWL、FR-SYNC、FR-INDEXREQ | 原文与来源、任务、处理及后续更新登记 |
| SPEC-DATA-01 | SPEC-02 | FR-CRAWL-004、FR-OUTCOME-004/007/008 | 规范字段、标识状态、质量标记 |
| SPEC-DATA-02 | SPEC-02 | FR-CRAWL-005/006、FR-OUTCOME-005 | 规范成果、来源映射、重复候选 |
| SPEC-DATA-03 | SPEC-02 | FR-SCHOLAR、SRS §4.1.1 | 独立人物 / 机构、候选与强标识关联 |
| SPEC-SEARCH-01 | SPEC-03 | FR-SEARCH、FR-ES、FR-OUTCOME-003 | 同版查询结果、分面、来源与状态 |
| SPEC-CLAIM-01 | SPEC-04 | FR-AUTH、FR-PORTAL、FR-INST、FR-INDEXREQ | 私有申请、审核历史和对象级有效授权 |
| SPEC-STAT-01 | SPEC-05 | FR-STAT、FR-INNOV、FR-REC | 统计快照、共著证据、最短路径；P1 推荐 |
| SPEC-QUALITY-01 | SPEC-02/05 和后台 | FR-ADMIN、FR-FEEDBACK、SRS §4.2 | 复核任务、质量报告、审计与恢复 |
| SPEC-TOOLS-01 | 原角色材料补充 | FR-TOOLS | P1 私人专题、笔记、比较和导出 |

关系数据库保存权威业务数据，检索索引可由其重建。内部成果 ID、来源 ID 和外部标识分别保存；账号、来源人物与门户管理权分别建模。原值、规范值、人工修订和来源证据均需保留。参与角色、日期含义和编号类型按成果类型解释。

每个处理结果记录 input_id、source_id、parser_version、rule_version、输出或错误状态及时间。错误至少区分非法输入、无权限、版本冲突、来源访问条件、来源超时、有效空结果、解析失败、质量隔离、待复核和公开版本失效。日志不得公开凭证、密码、私人笔记或完整认领证明。

# 2 SPEC-INGEST-01 数据采集与增量同步

## 2.1 目标和输入输出

接收来源、访问配置引用、成果类型、范围、时间窗口、游标 / 快照版本、频率和规则版本。输出原始内容版本、来源记录、采集观测、规范处理任务、处理状态及后续索引 / 统计更新登记。四类来源都应有独立适配契约；未验证的适配器不得以枚举存在声称已经接入。

Crossref 用于 DOI / ISSN 定向题录采集，OpenAlex API / 快照作为规模及主题数据候选，DBLP 作为计算机学科书目补充。专利、项目和获奖按具体公告来源接入。启用前登记访问方式、许可、频率、凭证、样本映射、时间及核验日期；配额、快照周期和接口状态按实际来源配置。

## 2.2 固定范围、幂等和检查点

1. 任务固定来源、范围、窗口开始和结束、配置及规则版本；Crossref 批量链路使用 cursor，不使用深页扫描。任务范围不是已确认学科。
2. 原始页写入后，事务持久化页内来源、原文引用、处理登记和下一页断点；提交成功才推进断点。原文件写入而事务失败可幂等重入，不能先推进游标后保存数据。
3. 来源稳定键与 raw_checksum 相同只新增观测 / last_seen，不新增重复成果。checksum 变化保留新原文版本；原文未变但解析或规则升级仍允许重处理。
4. 已成功同步水位只在整个窗口规范处理、入库校验及后续更新登记可靠完成后推进；分页断点只表示任务恢复位置，不能代替成功水位。失败重跑窗口保持幂等。
5. 公告记录在一次采集中缺席时，不自动删除；撤销或字段变化需记录依据并复核。人工确认并锁定的字段遇到来源冲突时进入复核。

## 2.3 六状态与处理阶段

任务使用 PENDING、RUNNING、SUCCEEDED、FAILED、RETRYING、STOPPED，遵循 SRS §4.1.3 与 §3.2.5.1。SUCCEEDED 指有界采集、解析清洗、规范处理及可靠提交完成，允许有明确计数的隔离 / 待复核结果，不能有未记录的页面丢失。公开索引和统计版本另记结果。

采集、解析和规范处理分别记录阶段结果。规范处理记录可使用 PENDING、PROCESSING、COMMITTED、REVIEW_REQUIRED、QUARANTINED、ERROR，与 CrawlTask 的六状态分开。

请求级短重试与任务级重试分开，记录预算和下一执行时间。网络异常、429、5xx 在来源规则允许下有限退避；429 尊重来源等待说明。配置错误、访问条件问题和结构整体变化应停止盲目重试并保留 FAILED。重试耗尽或人工终止时转为 STOPPED，并保留原失败记录及停止原因。

管理员 stop_requested 不等于立即退出。执行器在请求前、批次提交前检查停止请求和有效执行尝试；在安全边界停止，保留已提交批次。租约 / 执行尝试失效后，旧执行器不得新写数据或通过成功回调推进水位。成功或停止后的再次采集创建新任务关联旧任务。

## 2.4 配置与候选参数

| 配置 | 候选值 | 使用要求 |
| --- | --- | --- |
| 单请求超时 | 15 秒 | 按来源试验确认，不是默认服务承诺 |
| 短重试 | 每页最多 3 次，退避 1/2/4 秒与抖动 | 与任务重试分别记数；来源等待要求优先 |
| 任务重试 | 最多 3 次 | 团队确认后配置，耗尽不自动再调度 |
| 解析失败阈值 | 5% | 待校准；明确分母、关键结构错误及允许隔离的范围 |

以上参数按来源测试后确定，并保存配置版本。

## 2.5 验收

覆盖停用来源、有效空页、200 网页外壳、访问受限、异常页、有限重试、运行停止、旧执行器回调、事务中断及幂等重跑。成功后所有来源可追溯；失败不推进整窗水位；索引失败不使补采申请提前完成。对应 AC-R16/23/26～28、AC-U08/09。

# 3 SPEC-DATA-01 清洗与字段规范化

## 3.1 固定处理顺序

解析编码 → HTML 实体解码与结构清理 → Unicode 显示规范化 → 空白处理 → 字段校验 → 独立比较键 → 受控词表映射 → 质量标记。保存原文、展示值、比较值和规则版本，不原地覆盖来源。

| 对象 | 统一处理规则 | 异常与边界 |
| --- | --- | --- |
| 显示题名 | NFC、实体解码、连续空白压缩，保留语义符号 | 无题名隔离；不生成题名补原文 |
| 比较题名 | 独立字段宽度转换、casefold、有限弱标点规则 | 保留 C++ 等技术符号；不能任意删全部标点 |
| 摘要 | 解析器移除脚本 / 样式 / 标签，保留段落和许可 | 不允许展示则只标状态；不生成假摘要 |
| DOI | 去明确前缀 / 解析 URL，trim、小写、格式校验 | 不任意删尾标点；格式、解析、元数据匹配是不同状态 |
| ORCID / ISSN | 标准分组、校验位，原值另存 | 格式正确不证明来源归属或账号控制 |
| ROR | 规范 ID 和完整引用，来源与机构层级保留 | 不将同域名多个机构自动并为一个 |
| 专利 / 项目编号 | text 保留字母、前导零，按主管机构 / 资助体系规则解析 | 不用统一转整数或粗暴删符号处理各国号码 |
| 姓名 | raw_name、display_name、name_key、alias 分开 | 保留中文与变音字符，拼音作别名；不改作者顺序 |
| 机构 | 原名、规范实体、别名、地域与有效期 | 历史署名不被当前任职覆盖；缺信息仅候选 |
| 日期 | 年 / 年月 / 日和值、精度、含义同时保存 | 不填造 1 月 1 日；来源发布日不是授权或资助日期 |
| 数值 | 引用分源非负整数与观察时刻 | 0 为已知 0，null 为缺失；不跨源相加 |
| 词表 | 成果类型、奖励体系 / 等级、分类映射与版本 | 未分类单列；不把不同奖项等级换成价值评分 |

读取 OpenAlex 倒排摘要时，按词位置恢复文本，检查负位置、异常长度、位置重叠和空洞。接入时核对实际字段结构，重建摘要的展示范围遵守来源许可。

## 3.2 字段状态与隔离

known、missing、pending、not_applicable 分开。缺来源、未知类型、空题名不能创建公开成果；缺摘要、DOI、年份或机构可保留明确缺失的基础记录，但不计入相应完整样本。无贡献对象的记录保留待补；正式单位奖允许单位贡献对象，不强造个人。错误外部标识不进入精确索引和唯一键。

项目分别记录资助年、批准或立项年、计划起止和实际结题。奖励提名者与完成人分开，单位奖只建立单位贡献关系。Crossref 历史 subject 保留在原文中；默认分类使用平台目录、可用来源主题或经确认的候选标签。

## 3.3 验收

合法及非法标识、HTML、多语言、长题名、缺失日期、前导零、0 与未知、单位奖、项目计划状态均须准备固定样本。抽样 500 条清洗正确率目标≥99%，覆盖率目标≥80%；统计输入、隔离、处理和公开数量，不能删除坏样本制造指标。对应 AC-R18～23、AC-U05/06。

# 4 SPEC-DATA-02 四类成果去重

## 4.1 一期可执行基线

| 对象 | 精确身份依据 | 候选及阻断 |
| --- | --- | --- |
| 论文 | 同来源稳定键；合法无冲突 DOI | 不同合法 DOI 阻断模糊合并；同 DOI 字段冲突不覆盖原主值；无 DOI 相似题名进入复核 |
| 专利公开文献 | authority + publication_number + kind_code | 申请公开与授权公告不合并文献；缺 kind_code 仅候选 |
| 专利申请 / 家族 | 申请按司法辖区+申请号；家族按有来源关系 | 家族不是公开文献或授权申请的等价唯一键 |
| 科研项目 | 资助机构+项目批准号，必要时包含计划范围 | 相同号码不同资助机构不合并；缺编号只人工复核；科学部编号与批准号分开 |
| 获奖 | 奖励体系+年度+来源项目编号；无编号用完整业务复合键核验 | 授奖机构、奖项、年度、类别等级、项目与对象必须相容；跨年度或明确等级冲突阻断 |

无 DOI 论文按题名指纹、年份和首作者键召回，避免全库两两比较。候选召回条件为：题名完全相同；三元组相似度≥0.75 且年份差≤1；或首作者比较键一致且题名词项 Jaccard≥0.60。以上条件需用标注集验证，召回后进入复核。

## 4.2 候选匹配评分

以下评分用于候选排序和人工复核。自动模糊合并默认关闭；启用前须通过标注集质量测试、强冲突检查及团队评审。

```
S_paper = 0.55*S_title + 0.20*S_author + 0.10*S_year
        + 0.10*S_venue + 0.05*S_pages
候选自动区间 >=0.92；原复核区间 [0.82,0.92)

S_award = 0.50*S_project + 0.20*S_person + 0.15*S_org
```

```
        + 0.10*S_category + 0.05*S_year
候选自动区间 >=0.93；原复核区间 [0.84,0.93)
```

分量均在[0,1]；题名采用固定规则的字符三元组计数向量余弦，作者 / 人员 / 机构采用已确认实体集合 Jaccard。两空集合、空向量和缺失均是无证据，计算贡献 0 且不重分权重，记录 null。匹配分数表示相似度，不代表身份一致的概率。

论文年份同年 1、差一年 0.5、差更大 0；出版物与页码 / 文章号经确认相同 1，冲突 0，未知贡献 0。将来启用自动区间也须具备题名、非空作者、年份、出版物四项证据且无硬冲突。只有相同题名最多贡献 0.55，不能归一化成 1。预印本与正式版本可建立版本关系，不直接吞并。

奖励项目名按题名规则，人物及单位按集合；类别与等级都同为 1，仅一同为 0.5，皆异为 0；同年度为 1。授奖机构、奖项体系、年份与等级硬冲突优先于高分。正式单位奖的个人分量可不适用，不重分权重，必要时人工确认。

分数低于原复核区间但题名高度相似、标识冲突或证据缺失，仍可按明确原因进入复核，不能仅因低分宣称已经确定不同实体。A 像 B、B 像 C 不能推断整簇同一；每次加入检查全部强标识及相容性，冲突或无法确认则人工处理。

## 4.3 合并输出及恢复

同一事务写规范成果、有效来源映射、字段主值依据、贡献和机构关系、旧实体 merged_into_id、规则版本、分量 / 阻断及审计。原 raw 版本不删除。旧公开链接可解析，私人收藏迁移规范 ID 并按同库唯一键去重，笔记权限不扩大。

回退先核对来源映射、关系变更及后续修订，必要时人工重放，不能盲目恢复旧表覆盖有效新编辑。重复执行同输入和规则不新增相同成果。自动规则启用后准确率目标≥98%，同时报告候选召回与漏合并，自动合并准确率与总体去重效果分别报告。

# 5 SPEC-DATA-03 人员与机构消歧

## 5.1 身份层次和一期规则

ORCID 区分 syntax_valid（格式）、source_asserted（可信来源人物关联）、authenticated_control（申请人认证控制证据）。格式合法或手填 iD 不证明账号控制。来源 ORCID 无冲突时可关联作者实体，冲突于已核实身份则复核；任何来源匹配都不直接授予门户管理权。

无可靠强标识保持来源级或独立人物，姓名、机构、共同作者与主题生成候选。中文常见同名和两个不同已确认 ORCID 不自动合并；机构变动携带时间，不单凭任职不同判为不同人。待合并作者不能在同一批互相充当已确认共同作者证据。

## 5.2 人员匹配候选评分

```
S_author = 0.30*S_name + 0.25*S_affiliation + 0.25*S_coauthor
         + 0.15*S_topic + 0.05*S_time
原候选自动区间 >=0.95；原复核区间 [0.85,0.95)
```

本期弱标识作者评分仅用于候选复核，自动开关默认关闭，遵守 SRS §4.1.1。姓名比较用已确认别名或固定字符规则；机构采用时间可比记录中的机构 ID 集合；共同作者仅

用已确认 ID；主题使用固定分类 / 词项向量；时间用已知成果年份区间交并比，都是弱证据。缺失贡献 0，不重分权重。单独同名最多 0.30 不能自动合并。

## 5.3 机构规范化

可信无冲突 ROR 精确关联；缺 ROR 时规范名、别名、国家、城市、域名只作候选，最终人工确认。学校与院系层级保留，明确汇总上级的范围。更名保留别名有效期；机构合并 / 拆分存历史关系，不改写旧成果机构。人物当前机构与署名机构分开。

测试覆盖同名不同人、同人不同名、任职变化、不同 ORCID、共享域名及机构历史。来源作者自动关联准确率目标≥97%，ROR 精确映射抽样准确率目标≥99%；未启用的弱标识规则不计入自动关联测试结果。

# 6 SPEC-SEARCH-01 检索与排序

## 6.1 输入与查询语义

请求包括 query、type、人物 ID、person_mode=all/any、机构 ID、author_scope=same_contribution/any_contribution、领域与子领域开关、年份或类型专属日期、来源 / 模拟筛选、sort、page/page_size 及数据版本。默认 page_size=10，最大 100。起年晚于终年、非法字段、越界页和类型不适用分别说明。

姓名先检索候选，用户确认后以 ID 查询。跨维度 AND，同维度多选 OR；all/any 明示。指定人的机构条件必须属于同一贡献关系，不能用两个独立数组交叉匹配。综合类型查询按类型解释时间，机构默认采用成果发生时关系。

精确合法 DOI、公开号、项目编号优先定位相应类型；项目编号结合资助机构，机构或批准计划歧义先提示。ORCID 定位人物、ROR 定位机构；这不是认领身份核验。无关键词且有筛选允许浏览，完全空条件按明确的最新收录顺序。

## 6.2 默认排序与调优参数

一期默认按文本相关度排序，BM25 字段权重的基准候选为 title^4、author_names^2.5、venue_name^2、abstract^1、discipline_labels^2。DOI 优先精确定位，DOI^6 保留为测试候选。参数采用前需记录查询集、测试结果和评审版本。

并列按业务年份降序、规范成果 ID 升序；未知年份置后。用户选择日期排序时按声明日期再相关度和 ID；引用排序固定同一来源观察，缺失置后。适用日期字段不混用。

以下按成果类型设置的权重用于对照调优，与上述 BM25 候选分别测试：

| 类型 | 文本权重候选 |
| --- | --- |
| 论文 | 题名 0.45、摘要 0.20、关键词 0.15、作者 0.10、出版源 0.05、机构 0.05 |
| 专利 | 题名 0.40、摘要 0.25、申请人 0.15、发明人 0.10、CPC0.10 |
| 奖励 | 项目名 0.45、完成人 0.20、完成单位 0.15、奖名 0.10、类别等级 0.10 |
| 项目 | 标题优先，项目号精确；负责人、资助机构、类别权重须另校准，不自拟未验证公式 |

论文复合排序候选为 Score=0.80×R_text+0.10×R_citation+0.05×R_recency+0.05×R_quality。启用前需确定分量归一化、领域与年份范围、来源、缺失处理及对照测试。被引量与 BM25 原始分不能直接相加；归一化须覆盖实际排序集合，仅在返回页计算会破坏全库排名。

all 类型默认按成果类型分组，或采用经校准的共同排序规则。不同索引的原始得分须经校准后比较；未启用复合公式时，使用文本相关度排序。

## 6.3 索引与公开版本

每规范成果一份索引文档，ID 为成果 ID；人物与机构有实体键，贡献关系使用能保留“同人同机构”语义的结构。分类树、规则、数据范围、索引和统计构建版本一致。业务变更可靠登记更新工作，失败可重建；不得在数据库提交而任务登记丢失后仍宣称更新成功。

候选发布流程为固定业务快照 → 构建索引与统计 → 验证计数、标识、来源和样例 → 标记 READY → 短事务切换公开版本指针。请求固定 release，详情和统计明细读取同版；保留旧版覆盖令牌有效期，失效返回 410 或对应可解释错误。权限实时校验，不因旧快照恢复已撤销授权。

## 6.4 验收

至少 50 组查询含人物确认、多作者、同贡献机构、四类专属字段、空条件、错误年份、不适用筛选、精确命中与无命中、缺失状态及稳定分页。G1-AT-01～24 和 AC-U01/02/11 采用固定模拟集合手算。至少 10,000 条、20 并发、预热 5 分钟目标 P95≤2 秒，详情≤1 秒，记录环境和错误率。

# 7 SPEC-CLAIM-01 身份、门户和成果管理

## 7.1 申请契约与材料

申请人、对象、申请类型、材料版本、证据、状态、审核占用及到期、提交 / 处理 / 撤回时刻、审核人 / 意见、旧申请关联分别记录。身份申请、门户管理权和具体成果贡献为不同对象。邮箱控制、认证 ORCID、公开机构页和代表作是组合证据候选；手填标识及同名不必然通过。课程模拟证据必须标注。

材料默认私有；仅本人和授权审核人员访问。上传验证大小和类型；来源 URL 只存证据，后端访问需受控采集，不直接获取任意用户地址。不默认采集身份证扫描件。

## 7.2 统一状态

门户认领按当前 04_认领申请状态图及 SRS §4.1.2 使用 DRAFT、PENDING_REVIEW、NEED_MORE_INFO、APPROVED、REJECTED、WITHDRAWN 六状态。DRAFT 首次提交校验通过进入 PENDING_REVIEW，校验失败保持 DRAFT；管理员在 PENDING_REVIEW 中审核，要求补充进入 NEED_MORE_INFO；补交校验通过回 PENDING_REVIEW，失败仍为 NEED_MORE_INFO。绑定冲突保持 PENDING_REVIEW 并保留原有权限。审核及唯一绑定成功进入 APPROVED，驳回进入 REJECTED。仅待审核和待补充可撤回为 WITHDRAWN；草稿放弃不新增状态迁移。

校验和审核不是单独业务状态。验证服务暂不可用保留当前状态并安排重试或人工处理；审核占用仅是内部锁，领取或释放不改变业务状态。三种终态保留历史，再申请使用新编号；通过后的解绑和贡献撤销另走治理。审核、补充、撤回的并发版本最多一个操作成功。

## 7.3 原子授权与维护边界

一账号最多一个本人门户，一门户最多一个有效管理账号。通过时锁定或原子校验对象、申请版本、有效绑定，状态、授权和审计在同一事务提交。竞争冲突返回 409 或等价业务结果并回待复核，不替换已有合法权限。

多人贡献成果可各有一条有效确认关系；同人同成果最多一条。个人可维护本人说明、标签及顺序，公共题录、作者顺序、机构、归属和合并必须审核。撤销只处理申请人的有效关系，保留公共成果和其他人关系。

论文缺失转经审核的定向补采；非论文补录先查精确键及候选，再发布新记录或关联已有记录。审核通过不是采集或发布完成；索引补采仅检索可见时完成。机构注册、身份申请及科研人员索引申请沿用 SRS 契约，私人申请明细不向他人公开。

## 7.4 验收

覆盖材料缺失、暂时验证失败、重复本人申请、他人竞争、并发审核 / 撤回、终态再申请、同一账号第二门户、越权字段、多人贡献撤销、补录重复及补采索引失败。对应 AC-R02～06/15/17/24/25/29、AC-U10。

# 8 SPEC-STAT-01 统计、合作网络与推荐

## 8.1 统计集合与口径

所有指标先固定公开数据版本、成果类型、领域、机构、业务时间及真实 / 模拟范围，按规范身份去重。排除未审核草稿、被合并旧实体和软删除；公开标注撤稿是否排除由显式条件控制。整体成果按类型身份计数，授权专利按申请实体，文献和家族另外命名。

机构按成果发生时关系全计数，同成果同机构一次；机构合计可大于全库总量。当前成员视图另设；领域多标签同理，多领域合计不等于全库。排名数量相同并列，稳定次序机构 ID，不称科研质量排名。

论文使用选定出版日期（统一默认 print、再 online、再 issued）；专利授权年度、项目资助年度、奖励年度分别计算；项目立项可另切维度，不用网页发布时间补成果时间。未知年份单列，月 / 日分析仅纳入相应精度，未结束年显示截至时间。

引用次数按同一来源的有效值汇总，缺失与 0 分开，并显示覆盖率。OA 的已开放、未开放和未知分别统计，注明分母；请求失败记为未知。热点频次按时间桶统计包含主题的不同成果，一项成果同词只计一次，占比以有效分析语料为分母。频次趋势与预测功能分别定义；分母为 0 时不显示百分比。

## 8.2 共著与最短路径

节点为可识别学者，边为所选有效论文的共同署名，边权等于不同共同论文数量；多人论文为每对作者各增一次，重复来源不增权。引用、共同机构和推荐关系都不生成共著边。

FR-INNOV-001 用未截断可用图计算最少边数路径，候选实现 BFS；起终点相同返回 0 边，多个等长路径返回按学者 ID 稳定选择的一条并说明，无路径表述为“当前范围未找到”。图受规模或超时限制时返回未完成或范围受限，不伪造无路径结论。每条路径边附证据成果和同版筛选。

路径验收采用人工构造图，覆盖等长路径、孤立点、仅引用但无共著、重复论文、过滤断边和节点截断。逐边核对共同论文是否属于当前范围，基础网络与路径功能分别验收。

## 8.3 P1 相关论文推荐

推荐候选来自内容相似、有依据的主题或出版物匹配。按规范成果 ID 去重并排除当前论文，默认 8 篇、最大 20 篇；每条附至少一个有证据的推荐理由。同出版物不等于同学科；摘要或标签缺失时使用 title、venue 和 year，无候选时返回空结果。建议等待上限为 1 秒，超时不阻塞主详情。

推荐排序及参数需单独版本和测试；行为个性化和潜在合作者推荐属于 P2，不默认使用私人历史。该 P1 能力不替代本规范的路径创新。

## 8.4 更新与验收

统计从同一版本的成果与关系中，按全库或声明范围聚合；校验后切换快照。失败时保留旧快照，重试不重复累加。本人管理状态、公开产出和管理员质量统计分别展示与授权，统计结果可打开同条件、同版本的明细。

按《需求条目与验收场景》§4.4 两论文样例和 G1-AT-15～22 验证总体、机构、领域、引用、OA 及网络。至少 10,000 条、20 并发预热 5 分钟，基础预聚合统计 P95 目标≤3 秒；记录实际环境、范围和版本。

# 9 SPEC-QUALITY-01 质量、人工复核与审计

复核类型覆盖论文 / 奖励重复、缺编号项目、作者 / 机构候选、强标识或字段冲突、认领归属纠错、来源结构与缺失。页面同时展示原字段、规范字段、来源、时刻、标识、分量、缺失、阻断及版本；支持合并、保持独立、版本关系、等待证据或字段修订。

复核提交携带任务版本和理由，过时任务返回冲突。复核决定、成果与关系变更、字段修订及审计在同一事务保存。人工锁定字段优先，来源新冲突进入复核；仅相同来源、相同语义的字段可按有效更新时间取主值。

质量报告按来源和类型列输入、可解析、规范处理、隔离、待复核、公开、字段完整、未分类、机构未匹配及失败数量。完整率分母包含适用记录和缺失项，不跨来源借用补充样本提高原来源指标。异常状态覆盖与实际解决率分别命名。

质量目标按 SRS §4.2 执行：核心字段完整率≥95%，来源追踪率 100%，清洗抽样正确率≥99%，自动去重准确率≥98%，作者自动关联准确率≥97%，ROR 抽样准确率≥99%，异常状态覆盖率≥95%。测试报告注明样本量、分层、标注依据、算法版本及实际结果。

# 10 SPEC-TOOLS-01 私人科研资料能力 P1

收藏、专题和笔记按 account_id 授权，收藏唯一键为账号、专题和规范成果 ID。成果合并时迁移引用并去重，笔记仍按原权限访问。笔记记录方法、条件、局限、资源版本及原文位置；保存失败时保留待保存内容，并提示状态。

导出范围为用户确认的集合或筛选快照，跨页选择须完整，文件注明数量、格式、版本、来源和缺失字段。CSV / BibTeX 导出处理文本被误解析为公式的风险。比较限定 2 至 10 篇论文，展示条件差异；研究创新性由用户判断。外链显示访问状态和来源，实验复现需另行验证。

私人检索保存与关注不默认触发通知。订阅和学术讨论 P2 需另定义权限、治理与取消契约。启用 P1 时验证两个账号隔离、重复收藏、合并旧 ID、跨页导出和保存恢复。

# 11 逻辑接口与错误契约

以下为 REST 接口设计候选，须保持 SRS 的业务语义及对象授权。路径调整时同步 OpenAPI、调用代码和测试。

| 方法与路径候选 | 用途 | 主要权限与结果 |
| --- | --- | --- |
| GET /api/works/search | 四类查询与分面 | 公开；有效条件、总数、items、数据版本与缺失 |
| GET /api/works/{id} | 成果详情 | 公开；规范 ID、类型、来源、贡献关系 |
| GET /api/persons/search | 人物候选 | 公开；同名分别列出、来源和代表作 |
| GET /api/persons/{id}/portal | 门户 | 公开字段；私有信息另校验 |
| POST /api/claim-applications | 门户申请 | 本人认证；幂等返回本人已有申请，不返回他人私有材料 |
| POST /api/admin/claim-applications/{id}/review | 审核 | 审核权限、申请版本和理由；原子授权 |
| POST /api/admin/harvest-tasks | 创建任务 | 管理员；固定范围、配置版本、task_id |
| GET /api/admin/harvest-tasks/{id} | 状态与进度 | 管理员；处理和公开阶段分开展示 |
| POST /api/admin/merge-reviews/{id}/decision | 复核 | 治理权限、版本、证据与理由 |
| GET /api/statistics/overview | 基础统计 | 公开；范围、口径、版本、明细入口 |
| GET /api/networks/shortest-path | 创新最短共著路径 | 公开；限定范围、证据、完成或受限状态 |
| POST /internal/data-cleaning/jobs | 来源清洗任务 | 内部授权；来源输入与 rule_version |
| GET /internal/data-cleaning/jobs/{id} | 处理数量和状态 | 内部授权；隔离 / 错误分开 |
| GET /internal/normalized-records/{id} | 规范字段与来源 | 内部治理；不暴露私有证明 |

错误响应统一含 error_code、message、request_id 和可安全展示的 details；401 未认证、403 无权限、409 版本 / 绑定冲突、422 非法或不适用参数、410 版本已清理、503

服务不可用为候选 HTTP 映射。长任务创建返回任务标识及查询入口，进度总数未知时只返回计数，不伪造百分比。

# 12 架构候选与评审项

系统按采集适配、ETL、关系业务库、原文存储、检索、门户与认证、统计和管理后台划分职责。PostgreSQL、Elasticsearch / OpenSearch / 华为云 CSS、对象存储、Python 采集及后端调度组件为选型候选；CodeArts 工程交付按课程要求执行。

选型须支持执行租约与尝试校验、同事务数据提交及后续任务登记、固定数据版本、实时权限、来源审计和旧版本恢复。公开快照表、Outbox 等可靠登记机制按架构评审结果选择。

设计评审需确定来源访问与字段映射、领域目录、身份材料、算法启用条件及阈值、查询集和分词、统计更新周期、重试与隔离参数、创新验收、P1 范围、部署产品、负责人及代码结构。变更同步 SPEC、SRS、模型、样例和测试。

# 13 规范、代码与测试追踪及 AI 辅助开发

| 规范 | 计划代码职责 | 必须覆盖的测试 |
| --- | --- | --- |
| INGEST-01 | 来源适配、任务执行与同步 | 窗口、分页、幂等、停止、重试、旧执行器、检查点 |
| DATA-01 | 解析与清洗 | 标识、HTML、多语言、日期、0 与缺失、角色、词表 |
| DATA-02 | 去重与来源映射 | 四类型、强 ID 冲突、缺证据、版本关系、合并恢复 |
| DATA-03 | 身份与机构关联 | 同名、强标识、时间和机构历史、候选不授权 |
| SEARCH-01 | 查询、索引和发布 | 人物、贡献机构、筛选、四类字段、排序分页、版本 |
| CLAIM-01 | 身份、申请与授权 | 状态、补充、并发、唯一绑定、终态、对象权限 |
| STAT-01 | 统计、网络和 P1 推荐 | 去重口径、明细一致、快照恢复、路径证据、推荐降级 |
| QUALITY-01 | 治理与审计 | 过时复核、字段锁定、来源、指标分母及回退 |
| TOOLS-01 | P1 专题与资料利用 | 私人隔离、集合导出、合并引用、保存恢复 |

实际代码目录、测试路径和负责人确定后，补充 FR、SPEC 版本、实现提交、测试及评审记录。清洗与去重消歧、检索排序、统计三个核心模块的行覆盖率目标均为≥80%，结果以测试报告为准。

AI 辅助开发可用于已明确规则的字段映射、参数校验、接口骨架、候选计算、日志和测试。开发人员负责复核来源映射、身份授权、状态转换、数据合并、排名、统计及恢复逻辑。自动合并、认领、参数和来源选择须按评审结果实现。按课程要求保存 AI 使用日志、至少 3 个人工修正案例及至少 2 项 Agentic Coding 答辩实践的真实记录。

# 14 修订记录

| 版本 | 日期 | 说明 |
| --- | --- | --- |
| v1.0 | 2026-10-10 | 合并数据处理与五模块规范，补充项目、认领、统计和科研资料利用规则，统一状态、分页与验收 |
| v1.1 | 2026-10-10 | 整理提交稿，精简来源说明，明确模块职责、参数使用条件及评审事项 |
| v1.2 | 2026-10-12 | 按当前 images 同步插图、状态与模型解释，采用 Draw.io 可编辑文件并列出缺图 |
| v2.0 | 2026-10-12 | 按参考格式统一封面、版本历史和目录；更新 SRS 章节引用及详细需求附录链接，保留核心模块规则 |

本版图文同步说明：按 2026 年 10 月 12 日 images 现存文件更新模型和解释；模型可编辑文件采用 Draw.io，未生成额外图片。缺少文件见 Submit 中的图文核对与缺图清单。

本版格式按参考仓库的封面、版本历史、目录及正文样式统一；模块内容沿用本组输入，参考仓库未提供独立 SPEC 模板。新用例与 FR 的完整对应见需求条目与验收场景。