学术成果检索与分享平台核心模块开发规范

版本：v1.2 | 日期：2026-10-12

本规范规定四类成果的采集、清洗、去重、身份匹配、检索、认领、统计及质量管理规则，包括模块输入输出、处理过程、异常恢复和验收方法。

需求与用例见 SRS，业务依据见调研报告，来源与修订情况见修订说明。算法参数和架构选型列为候选，采用前需完成固定样本测试和设计评审；性能要求为验收目标。

1 规范编号与共同契约

规范按九个模块编号，每项关联需求、模块输出和测试。早期五模块编号的对应关系保留，便于追踪。

规范编号	早期模块编号	对应需求	模块输出
SPEC-INGEST-01	SPEC-01	FR-CRAWL、FR-SYNC、FR-INDEXREQ	原文与来源、任务、处理及后续更新登记
SPEC-DATA-01	SPEC-02	FR-CRAWL-004、FR-OUTCOME-004/007/008	规范字段、标识状态、质量标记
SPEC-DATA-02	SPEC-02	FR-CRAWL-005/006、FR-OUTCOME-005	规范成果、来源映射、重复候选
SPEC-DATA-03	SPEC-02	FR-SCHOLAR、SRS §6.2～6.3	独立人物 / 机构、候选与强标识关联
SPEC-SEARCH-01	SPEC-03	FR-SEARCH、FR-ES、FR-OUTCOME-003	同版查询结果、分面、来源与状态
SPEC-CLAIM-01	SPEC-04	FR-AUTH、FR-PORTAL、FR-INST、FR-INDEXREQ	私有申请、审核历史和对象级有效授权
SPEC-STAT-01	SPEC-05	FR-STAT、FR-INNOV、FR-REC	统计快照、共著证据、最短路径；P1 推荐
SPEC-QUALITY-01	SPEC-02/05 和后台	FR-ADMIN、FR-FEEDBACK、SRS §8.9	复核任务、质量报告、审计与恢复
SPEC-TOOLS-01	原角色材料补充	FR-TOOLS	P1 私人专题、笔记、比较和导出

关系数据库保存权威业务数据，检索索引可由其重建。内部成果 ID、来源 ID 和外部标识分别保存；账号、来源人物与门户管理权分别建模。原值、规范值、人工修订和来源证据均需保留。参与角色、日期含义和编号类型按成果类型解释。

每个处理结果记录 input_id、source_id、parser_version、rule_version、输出或错误状态及时间。错误至少区分非法输入、无权限、版本冲突、来源访问条件、来源超时、有效空结果、解析失败、质量隔离、待复核和公开版本失效。日志不得公开凭证、密码、私人笔记或完整认领证明。

2 SPEC-INGEST-01 数据采集与增量同步

2.1 目标和输入输出

接收来源、访问配置引用、成果类型、范围、时间窗口、游标 / 快照版本、频率和规则版本。输出原始内容版本、来源记录、采集观测、规范处理任务、处理状态及后续索引 / 统计更新登记。四类来源都应有独立适配契约；未验证的适配器不得以枚举存在声称已经接入。

Crossref 用于 DOI / ISSN 定向题录采集，OpenAlex API / 快照作为规模及主题数据候选，DBLP 作为计算机学科书目补充。专利、项目和获奖按具体公告来源接入。启用前登记访问方式、许可、频率、凭证、样本映射、时间及核验日期；配额、快照周期和接口状态按实际来源配置。

2.2 固定范围、幂等和检查点

1. 任务固定来源、范围、窗口开始和结束、配置及规则版本；Crossref 批量链路使用 cursor，不使用深页扫描。任务范围不是已确认学科。
2. 原始页写入后，事务持久化页内来源、原文引用、处理登记和下一页断点；提交成功才推进断点。原文件写入而事务失败可幂等重入，不能先推进游标后保存数据。
3. 来源稳定键与 raw_checksum 相同只新增观测 / last_seen，不新增重复成果。checksum 变化保留新原文版本；原文未变但解析或规则升级仍允许重处理。
4. 已成功同步水位只在整个窗口规范处理、入库校验及后续更新登记可靠完成后推进；分页断点只表示任务恢复位置，不能代替成功水位。失败重跑窗口保持幂等。
5. 公告记录在一次采集中缺席时，不自动删除；撤销或字段变化需记录依据并复核。人工确认并锁定的字段遇到来源冲突时进入复核。

2.3 六状态与处理阶段

任务使用 PENDING、RUNNING、SUCCEEDED、FAILED、RETRYING、STOPPED，遵循 SRS §6.9 与 §13.3。SUCCEEDED 指有界采集、解析清洗、规范处理及可靠提交完成，允许有明确计数的隔离 / 待复核结果，不能有未记录的页面丢失。公开索引和统计版本另记结果。

采集、解析和规范处理分别记录阶段结果。规范处理记录可使用 PENDING、PROCESSING、COMMITTED、REVIEW_REQUIRED、QUARANTINED、ERROR，与 CrawlTask 的六状态分开。

请求级短重试与任务级重试分开，记录预算和下一执行时间。网络异常、429、5xx 在来源规则允许下有限退避；429 尊重来源等待说明。配置错误、访问条件问题和结构整体变化应停止盲目重试并保留 FAILED。重试耗尽或人工终止时转为 STOPPED，并保留原失败记录及停止原因。

管理员 stop_requested 不等于立即退出。执行器在请求前、批次提交前检查停止请求和有效执行尝试；在安全边界停止，保留已提交批次。租约 / 执行尝试失效后，旧执行器不得新写数据或通过成功回调推进水位。成功或停止后的再次采集创建新任务关联旧任务。

2.4 配置与候选参数

配置	候选值	使用要求
单请求超时	15 秒	按来源试验确认，不是默认服务承诺
短重试	每页最多 3 次，退避 1/2/4 秒与抖动	与任务重试分别记数；来源等待要求优先

配置	候选值	使用要求
任务重试	最多 3 次	团队确认后配置，耗尽不自动再调度
解析失败阈值	5%	待校准；明确分母、关键结构错误及允许隔离的范围

以上参数按来源测试后确定，并保存配置版本。

2.5 验收

覆盖停用来源、有效空页、200 网页外壳、访问受限、异常页、有限重试、运行停止、旧执行器回调、事务中断及幂等重跑。成功后所有来源可追溯；失败不推进整窗水位；索引失败不使补采申请提前完成。对应 AC-R16/23/26～28、AC-U08/09。

3 SPEC-DATA-01 清洗与字段规范化

3.1 固定处理顺序

解析编码 → HTML 实体解码与结构清理 → Unicode 显示规范化 → 空白处理 → 字段校验 → 独立比较键 → 受控词表映射 → 质量标记。保存原文、展示值、比较值和规则版本，不原地覆盖来源。

对象	统一处理规则	异常与边界
显示题名	NFC、实体解码、连续空白压缩，保留语义符号	无题名隔离；不生成题名补原文
比较题名	独立字段宽度转换、casefold、有限弱标点规则	保留 C++ 等技术符号；不能任意删全部标点
摘要	解析器移除脚本 / 样式 / 标签，保留段落和许可	不允许展示则只标状态；不生成假摘要
DOI	去明确前缀 / 解析 URL，trim、小写、格式校验	不任意删尾标点；格式、解析、元数据匹配是不同状态
ORCID / ISSN	标准分组、校验位，原值另存	格式正确不证明来源归属或账号控制
ROR	规范 ID 和完整引用，来源与机构层级保留	不将同域名多个机构自动并为一个
专利 / 项目编号	text 保留字母、前导零，按主管机构 / 资助体系规则解析	不用统一转整数或粗暴删符号处理各国号码
姓名	raw_name、display_name、name_key、alias 分开	保留中文与变音字符，拼音作别名；不改作者顺序
机构	原名、规范实体、别名、地域与有效期	历史署名不被当前任职覆盖；缺信息仅候选
日期	年 / 年月 / 日和值、精度、含义同时保存	不填造 1 月 1 日；来源发布日不是授权或资助日期
数值	引用分源非负整数与观察时刻	0 为已知 0，null 为缺失；不跨源相加
词表	成果类型、奖励体系 / 等级、分类映射与版本	未分类单列；不把不同奖项等级换成价值评分

读取 OpenAlex 倒排摘要时，按词位置恢复文本，检查负位置、异常长度、位置重叠和空洞。接入时核对实际字段结构，重建摘要的展示范围遵守来源许可。

3.2 字段状态与隔离

known、missing、pending、not_applicable 分开。缺来源、未知类型、空题名不能创建公开成果；缺摘要、DOI、年份或机构可保留明确缺失的基础记录，但不计入相应完整样本。无贡献对象的记录保留待补；正式单位奖允许单位贡献对象，不强造个人。错误外部标识不进入精确索引和唯一键。

项目分别记录资助年、批准或立项年、计划起止和实际结题。奖励提名者与完成人分开，单位奖只建立单位贡献关系。Crossref 历史 subject 保留在原文中；默认分类使用平台目录、可用来源主题或经确认的候选标签。

3.3 验收

合法及非法标识、HTML、多语言、长题名、缺失日期、前导零、0 与未知、单位奖、项目计划状态均须准备固定样本。抽样 500 条清洗正确率目标≥99%，覆盖率目标≥80%；统计输入、隔离、处理和公开数量，不能删除坏样本制造指标。对应 AC-R18～23、AC-U05/06。

4 SPEC-DATA-02 四类成果去重

4.1 一期可执行基线

对象	精确身份依据	候选及阻断
论文	同来源稳定键；合法无冲突 DOI	不同合法 DOI 阻断模糊合并；同 DOI 字段冲突不覆盖原主值；无 DOI 相似题名进入复核
专利公开文献	authority + publication_number + kind_code	申请公开与授权公告不合并文献；缺 kind_code 仅候选
专利申请 / 家族	申请按司法辖区+申请号；家族按有来源关系	家族不是公开文献或授权申请的等价唯一键
科研项目	资助机构+项目批准号，必要时包含计划范围	相同号码不同资助机构不合并；缺编号只人工复核；科学部编号与批准号分开
获奖	奖励体系+年度+来源项目编号；无编号用完整业务复合键核验	授奖机构、奖项、年度、类别等级、项目与对象必须相容；跨年度或明确等级冲突阻断

无 DOI 论文按题名指纹、年份和首作者键召回，避免全库两两比较。候选召回条件为：题名完全相同；三元组相似度≥0.75 且年份差≤1；或首作者比较键一致且题名词项 Jaccard≥0.60。以上条件需用标注集验证，召回后进入复核。

4.2 候选匹配评分

以下评分用于候选排序和人工复核。自动模糊合并默认关闭；启用前须通过标注集质量测试、强冲突检查及团队评审。

```
S_paper = 0.55*S_title + 0.20*S_author + 0.10*S_year
        + 0.10*S_venue + 0.05*S_pages
候选自动区间 >=0.92；原复核区间 [0.82,0.92)

S_award = 0.50*S_project + 0.20*S_person + 0.15*S_org
        + 0.10*S_category + 0.05*S_year
候选自动区间 >=0.93；原复核区间 [0.84,0.93)
```

分量均在[0,1]；题名采用固定规则的字符三元组计数向量余弦，作者 / 人员 / 机构采用已确认实体集合 Jaccard。两空集合、空向量和缺失均是无证据，计算贡献 0 且不重分权重，记录 null。匹配分数表示相似度，不代表身份一致的概率。

论文年份同年 1、差一年 0.5、差更大 0；出版物与页码 / 文章号经确认相同 1，冲突 0，未知贡献 0。将来启用自动区间也须具备题名、非空作者、年份、出版物四项证据且无硬冲突。只有相同题名最多贡献 0.55，不能归一化成 1。预印本与正式版本可建立版本关系，不直接吞并。

奖励项目名按题名规则，人物及单位按集合；类别与等级都同为 1，仅一同为 0.5，皆异为 0；同年度为 1。授奖机构、奖项体系、年份与等级硬冲突优先于高分。正式单位奖的个人分量可不适用，不重分权重，必要时人工确认。

分数低于原复核区间但题名高度相似、标识冲突或证据缺失，仍可按明确原因进入复核，不能仅因低分宣称已经确定不同实体。A 像 B、B 像 C 不能推断整簇同一；每次加入检查全部强标识及相容性，冲突或无法确认则人工处理。

4.3 合并输出及恢复

同一事务写规范成果、有效来源映射、字段主值依据、贡献和机构关系、旧实体 merged_into_id、规则版本、分量 / 阻断及审计。原 raw 版本不删除。旧公开链接可解析，私人收藏迁移规范 ID 并按同库唯一键去重，笔记权限不扩大。

回退先核对来源映射、关系变更及后续修订，必要时人工重放，不能盲目恢复旧表覆盖有效新编辑。重复执行同输入和规则不新增相同成果。自动规则启用后准确率目标≥98%，同时报告候选召回与漏合并，自动合并准确率与总体去重效果分别报告。

5 SPEC-DATA-03 人员与机构消歧

5.1 身份层次和一期规则

ORCID 区分 syntax_valid（格式）、source_asserted（可信来源人物关联）、authenticated_control（申请人认证控制证据）。格式合法或手填 iD 不证明账号控制。来源 ORCID 无冲突时可关联作者实体，冲突于已核实身份则复核；任何来源匹配都不直接授予门户管理权。

无可靠强标识保持来源级或独立人物，姓名、机构、共同作者与主题生成候选。中文常见同名和两个不同已确认 ORCID 不自动合并；机构变动携带时间，不单凭任职不同判为不同人。待合并作者不能在同一批互相充当已确认共同作者证据。

5.2 人员匹配候选评分

```
S_author = 0.30*S_name + 0.25*S_affiliation + 0.25*S_coauthor
         + 0.15*S_topic + 0.05*S_time
```

原候选自动区间 >=0.95；原复核区间 [0.85,0.95)

本期弱标识作者评分仅用于候选复核，自动开关默认关闭，遵守 SRS §6.2。姓名比较用已确认别名或固定字符规则；机构采用时间可比记录中的机构 ID 集合；共同作者仅用已确认 ID；主题使用固定分类 / 词项向量；时间用已知成果年份区间交并比，都是弱证据。缺失贡献 0，不重分权重。单独同名最多 0.30 不能自动合并。

5.3 机构规范化

可信无冲突 ROR 精确关联；缺 ROR 时规范名、别名、国家、城市、域名只作候选，最终人工确认。学校与院系层级保留，明确汇总上级的范围。更名保留别名有效期；机构合并 / 拆分存历史关系，不改写旧成果机构。人物当前机构与署名机构分开。

测试覆盖同名不同人、同人不同名、任职变化、不同 ORCID、共享域名及机构历史。来源作者自动关联准确率目标≥97%，ROR 精确映射抽样准确率目标≥99%；未启用的弱标识规则不计入自动关联测试结果。

6 SPEC-SEARCH-01 检索与排序

6.1 输入与查询语义

请求包括 query、type、人物 ID、person_mode=all/any、机构 ID、author_scope=same_contribution/any_contribution、领域与子领域开关、年份或类型专属日期、来源 / 模拟筛选、sort、page/page_size 及数据版本。默认 page_size=10，最大 100。起年晚于终年、非法字段、越界页和类型不适用分别说明。

姓名先检索候选，用户确认后以 ID 查询。跨维度 AND，同维度多选 OR；all/any 明示。指定人的机构条件必须属于同一贡献关系，不能用两个独立数组交叉匹配。综合类型查询按类型解释时间，机构默认采用成果发生时关系。

精确合法 DOI、公开号、项目编号优先定位相应类型；项目编号结合资助机构，机构或批准计划歧义先提示。ORCID 定位人物、ROR 定位机构；这不是认领身份核验。无关键词且有筛选允许浏览，完全空条件按明确的最新收录顺序。

6.2 默认排序与调优参数

一期默认按文本相关度排序，BM25 字段权重的基准候选为 title^4、author_names^2.5、venue_name^2、abstract^1、discipline_labels^2。DOI 优先精确定位，DOI^6 保留为测试候选。参数采用前需记录查询集、测试结果和评审版本。

并列按业务年份降序、规范成果 ID 升序；未知年份置后。用户选择日期排序时按声明日期再相关度和 ID；引用排序固定同一来源观察，缺失置后。适用日期字段不混用。

以下按成果类型设置的权重用于对照调优，与上述 BM25 候选分别测试：

类型	文本权重候选
论文	题名 0.45、摘要 0.20、关键词 0.15、作者 0.10、出版源 0.05、机构 0.05
专利	题名 0.40、摘要 0.25、申请人 0.15、发明人 0.10、CPC0.10
奖励	项目名 0.45、完成人 0.20、完成单位 0.15、奖名 0.10、类别等级 0.10
项目	标题优先，项目号精确；负责人、资助机构、类别权重须另校准，不自拟未验证公式

论文复合排序候选为 Score=0.80×R_text+0.10×R_citation+0.05×R_recency+0.05×R_quality。启用前需确定分量归一化、领域与年份范围、来源、缺失处理及对照测试。被引量与 BM25 原始分不能直接相加；归一化须覆盖实际排序集合，仅在返回页计算会破坏全库排名。

all 类型默认按成果类型分组，或采用经校准的共同排序规则。不同索引的原始得分须经校准后比较；未启用复合公式时，使用文本相关度排序。

6.3 索引与公开版本

每规范成果一份索引文档，ID 为成果 ID；人物与机构有实体键，贡献关系使用能保留“同人同机构”语义的结构。分类树、规则、数据范围、索引和统计构建版本一致。业务变更可靠登记更新工作，失败可重建；不得在数据库提交而任务登记丢失后仍宣称更新成功。

候选发布流程为固定业务快照 → 构建索引与统计 → 验证计数、标识、来源和样例 → 标记 READY → 短事务切换公开版本指针。请求固定 release，详情和统计明细读取同版；保留旧版覆盖令牌有效期，失效返回 410 或对应可解释错误。权限实时校验，不因旧快照恢复已撤销授权。

6.4 验收

至少 50 组查询含人物确认、多作者、同贡献机构、四类专属字段、空条件、错误年份、不适用筛选、精确命中与无命中、缺失状态及稳定分页。G1-AT-01～24 和 AC-U01/02/11 采用固定模拟集合手算。至少 10,000 条、20 并发、预热 5 分钟目标 P95≤2 秒，详情≤1 秒，记录环境和错误率。

7 SPEC-CLAIM-01 身份、门户和成果管理

7.1 申请契约与材料

申请人、对象、申请类型、材料版本、证据、状态、审核占用及到期、提交 / 处理 / 撤回时刻、审核人 / 意见、旧申请关联分别记录。身份申请、门户管理权和具体成果贡献为不同对象。邮箱控制、认证 ORCID、公开机构页和代表作是组合证据候选；手填标识及同名不必然通过。课程模拟证据必须标注。

材料默认私有；仅本人和授权审核人员访问。上传验证大小和类型；来源 URL 只存证据，后端访问需受控采集，不直接获取任意用户地址。不默认采集身份证扫描件。

7.2 统一状态

门户认领按当前 04_认领申请状态图及 SRS §6.8 使用 DRAFT、PENDING_REVIEW、NEED_MORE_INFO、APPROVED、REJECTED、WITHDRAWN 六状态。DRAFT 首次提交校验通过进入 PENDING_REVIEW，校验失败保持 DRAFT；管理员在 PENDING_REVIEW 中审核，要求补充进入 NEED_MORE_INFO；补交校验通过回 PENDING_REVIEW，失败仍为 NEED_MORE_INFO。绑定冲突保持 PENDING_REVIEW 并保留原有权限。审核及唯一绑定成功进入 APPROVED，驳回进入 REJECTED。仅待审核和待补充可撤回为 WITHDRAWN；草稿放弃不新增状态迁移。

校验和审核不是单独业务状态。验证服务暂不可用保留当前状态并安排重试或人工处理；审核占用仅是内部锁，领取或释放不改变业务状态。三种终态保留历史，再申请使用新编号；通过后的解绑和贡献撤销另走治理。审核、补充、撤回的并发版本最多一个操作成功。

7.3 原子授权与维护边界

一账号最多一个本人门户，一门户最多一个有效管理账号。通过时锁定或原子校验对象、申请版本、有效绑定，状态、授权和审计在同一事务提交。竞争冲突返回 409 或等价业务结果并回待复核，不替换已有合法权限。

多人贡献成果可各有一条有效确认关系；同人同成果最多一条。个人可维护本人说明、标签及顺序，公共题录、作者顺序、机构、归属和合并必须审核。撤销只处理申请人的有效关系，保留公共成果和其他人关系。

论文缺失转经审核的定向补采；非论文补录先查精确键及候选，再发布新记录或关联已有记录。审核通过不是采集或发布完成；索引补采仅检索可见时完成。机构注册、身份申请及科研人员索引申请沿用 SRS 契约，私人申请明细不向他人公开。

7.4 验收

覆盖材料缺失、暂时验证失败、重复本人申请、他人竞争、并发审核 / 撤回、终态再申请、同一账号第二门户、越权字段、多人贡献撤销、补录重复及补采索引失败。对应 AC-R02～06/15/17/24/25/29、AC-U10。

8 SPEC-STAT-01 统计、合作网络与推荐

8.1 统计集合与口径

所有指标先固定公开数据版本、成果类型、领域、机构、业务时间及真实 / 模拟范围，按规范身份去重。排除未审核草稿、被合并旧实体和软删除；公开标注撤稿是否排除由显式条件控制。整体成果按类型身份计数，授权专利按申请实体，文献和家族另外命名。

机构按成果发生时关系全计数，同成果同机构一次；机构合计可大于全库总量。当前成员视图另设；领域多标签同理，多领域合计不等于全库。排名数量相同并列，稳定次序机构 ID，不称科研质量排名。

论文使用选定出版日期（统一默认 print、再 online、再 issued）；专利授权年度、项目资助年度、奖励年度分别计算；项目立项可另切维度，不用网页发布时间补成果时间。未知年份单列，月 / 日分析仅纳入相应精度，未结束年显示截至时间。

引用次数按同一来源的有效值汇总，缺失与 0 分开，并显示覆盖率。OA 的已开放、未开放和未知分别统计，注明分母；请求失败记为未知。热点频次按时间桶统计包含主题的不同成果，一项成果同词只计一次，占比以有效分析语料为分母。频次趋势与预测功能分别定义；分母为 0 时不显示百分比。

8.2 共著与最短路径

节点为可识别学者，边为所选有效论文的共同署名，边权等于不同共同论文数量；多人论文为每对作者各增一次，重复来源不增权。引用、共同机构和推荐关系都不生成共著边。

FR-INNOV-001 用未截断可用图计算最少边数路径，候选实现 BFS；起终点相同返回 0 边，多个等长路径返回按学者 ID 稳定选择的一条并说明，无路径表述为“当前范围未找到”。图受规模或超时限制时返回未完成或范围受限，不伪造无路径结论。每条路径边附证据成果和同版筛选。

路径验收采用人工构造图，覆盖等长路径、孤立点、仅引用但无共著、重复论文、过滤断边和节点截断。逐边核对共同论文是否属于当前范围，基础网络与路径功能分别验收。

8.3 P1 相关论文推荐

推荐候选来自内容相似、有依据的主题或出版物匹配。按规范成果 ID 去重并排除当前论文，默认 8 篇、最大 20 篇；每条附至少一个有证据的推荐理由。同出版物不等于同学科；摘要或标签缺失时使用 title、venue 和 year，无候选时返回空结果。建议等待上限为 1 秒，超时不阻塞主详情。

推荐排序及参数需单独版本和测试；行为个性化和潜在合作者推荐属于 P2，不默认使用私人历史。该 P1 能力不替代本规范的路径创新。

8.4 更新与验收

统计从同一版本的成果与关系中，按全库或声明范围聚合；校验后切换快照。失败时保留旧快照，重试不重复累加。本人管理状态、公开产出和管理员质量统计分别展示与授权，统计结果可打开同条件、同版本的明细。

按 SRS §6.4 两论文样例和 G1-AT-15～22 验证总体、机构、领域、引用、OA 及网络。至少 10,000 条、20 并发预热 5 分钟，基础预聚合统计 P95 目标≤3 秒；记录实际环境、范围和版本。

9 SPEC-QUALITY-01 质量、人工复核与审计

复核类型覆盖论文 / 奖励重复、缺编号项目、作者 / 机构候选、强标识或字段冲突、认领归属纠错、来源结构与缺失。页面同时展示原字段、规范字段、来源、时刻、标识、分量、缺失、阻断及版本；支持合并、保持独立、版本关系、等待证据或字段修订。

复核提交携带任务版本和理由，过时任务返回冲突。复核决定、成果与关系变更、字段修订及审计在同一事务保存。人工锁定字段优先，来源新冲突进入复核；仅相同来源、相同语义的字段可按有效更新时间取主值。

质量报告按来源和类型列输入、可解析、规范处理、隔离、待复核、公开、字段完整、未分类、机构未匹配及失败数量。完整率分母包含适用记录和缺失项，不跨来源借用补充样本提高原来源指标。异常状态覆盖与实际解决率分别命名。

质量目标按 SRS §8.9 执行：核心字段完整率≥95%，来源追踪率 100%，清洗抽样正确率≥99%，自动去重准确率≥98%，作者自动关联准确率≥97%，ROR 抽样准确率≥99%，异常状态覆盖率≥95%。测试报告注明样本量、分层、标注依据、算法版本及实际结果。

10 SPEC-TOOLS-01 私人科研资料能力 P1

收藏、专题和笔记按 account_id 授权，收藏唯一键为账号、专题和规范成果 ID。成果合并时迁移引用并去重，笔记仍按原权限访问。笔记记录方法、条件、局限、资源版本及原文位置；保存失败时保留待保存内容，并提示状态。

导出范围为用户确认的集合或筛选快照，跨页选择须完整，文件注明数量、格式、版本、来源和缺失字段。CSV / BibTeX 导出处理文本被误解析为公式的风险。比较限定 2 至 10 篇论文，展示条件差异；研究创新性由用户判断。外链显示访问状态和来源，实验复现需另行验证。

私人检索保存与关注不默认触发通知。订阅和学术讨论 P2 需另定义权限、治理与取消契约。启用 P1 时验证两个账号隔离、重复收藏、合并旧 ID、跨页导出和保存恢复。

11 逻辑接口与错误契约

以下为 REST 接口设计候选，须保持 SRS 的业务语义及对象授权。路径调整时同步 OpenAPI、调用代码和测试。

方法与路径候选	用途	主要权限与结果
GET /api/works/search	四类查询与分面	公开；有效条件、总数、items、数据版本与缺失
GET /api/works/{id}	成果详情	公开；规范 ID、类型、来源、贡献关系

方法与路径候选	用途	主要权限与结果
GET /api/persons/search	人物候选	公开；同名分别列出、来源和代表作
GET /api/persons/{id}/portal	门户	公开字段；私有信息另校验
POST /api/claim-applications	门户申请	本人认证；幂等返回本人已有申请，不返回他人私有材料
POST /api/admin/claim-applications/{id}/review	审核	审核权限、申请版本和理由；原子授权
POST /api/admin/harvest-tasks	创建任务	管理员；固定范围、配置版本、task_id
GET /api/admin/harvest-tasks/{id}	状态与进度	管理员；处理和公开阶段分开展示
POST /api/admin/merge-reviews/{id}/decision	复核	治理权限、版本、证据与理由
GET /api/statistics/overview	基础统计	公开；范围、口径、版本、明细入口
GET /api/networks/shortest-path	创新最短共著路径	公开；限定范围、证据、完成或受限状态
POST /internal/data-cleaning/jobs	来源清洗任务	内部授权；来源输入与 rule_version
GET /internal/data-cleaning/jobs/{id}	处理数量和状态	内部授权；隔离 / 错误分开
GET /internal/normalized-records/{id}	规范字段与来源	内部治理；不暴露私有证明

错误响应统一含 error_code、message、request_id 和可安全展示的 details；401 未认证、403 无权限、409 版本 / 绑定冲突、422 非法或不适用参数、410 版本已清理、503 服务不可用为候选 HTTP 映射。长任务创建返回任务标识及查询入口，进度总数未知时只返回计数，不伪造百分比。

12 架构候选与评审项

系统按采集适配、ETL、关系业务库、原文存储、检索、门户与认证、统计和管理后台划分职责。PostgreSQL、Elasticsearch / OpenSearch / 华为云 CSS、对象存储、Python 采集及后端调度组件为选型候选；CodeArts 工程交付按课程要求执行。

选型须支持执行租约与尝试校验、同事务数据提交及后续任务登记、固定数据版本、实时权限、来源审计和旧版本恢复。公开快照表、Outbox 等可靠登记机制按架构评审结果选择。

设计评审需确定来源访问与字段映射、领域目录、身份材料、算法启用条件及阈值、查询集和分词、统计更新周期、重试与隔离参数、创新验收、P1 范围、部署产品、负责人及代码结构。变更同步 SPEC、SRS、模型、样例和测试。

13 规范、代码与测试追踪及 AI 辅助开发

规范	计划代码职责	必须覆盖的测试
INGEST-01	来源适配、任务执行与同步	窗口、分页、幂等、停止、重试、旧执行器、检查点
DATA-01	解析与清洗	标识、HTML、多语言、日期、0 与缺失、角色、词表
DATA-02	去重与来源映射	四类型、强 ID 冲突、缺证据、版本关系、合并恢复
DATA-03	身份与机构关联	同名、强标识、时间和机构历史、候选不授权

规范	计划代码职责	必须覆盖的测试
SEARCH-01	查询、索引和发布	人物、贡献机构、筛选、四类字段、排序分页、版本
CLAIM-01	身份、申请与授权	状态、补充、并发、唯一绑定、终态、对象权限
STAT-01	统计、网络和 P1 推荐	去重口径、明细一致、快照恢复、路径证据、推荐降级
QUALITY-01	治理与审计	过时复核、字段锁定、来源、指标分母及回退
TOOLS-01	P1 专题与资料利用	私人隔离、集合导出、合并引用、保存恢复

实际代码目录、测试路径和负责人确定后，补充 FR、SPEC 版本、实现提交、测试及评审记录。清洗与去重消歧、检索排序、统计三个核心模块的行覆盖率目标均为≥80%，结果以测试报告为准。

AI 辅助开发可用于已明确规则的字段映射、参数校验、接口骨架、候选计算、日志和测试。开发人员负责复核来源映射、身份授权、状态转换、数据合并、排名、统计及恢复逻辑。自动合并、认领、参数和来源选择须按评审结果实现。按课程要求保存 AI 使用日志、至少 3 个人工修正案例及至少 2 项 Agentic Coding 答辩实践的真实记录。

14 修订记录

版本	日期	说明
v1.0	2026-10-10	合并数据处理与五模块规范，补充项目、认领、统计和科研资料利用规则，统一状态、分页与验收
v1.1	2026-10-10	整理提交稿，精简来源说明，明确模块职责、参数使用条件及评审事项
v1.2	2026-10-12	按当前 images 同步插图、状态与模型解释，采用 Draw.io 可编辑文件并列出缺图